

[russian]rmTimes New Roman

МИНИСТЕРСТВО ЦИФРОВОГО РАЗВИТИЯ, СВЯЗИ И МАССОВЫХ
КОММУНИКАЦИЙ
РОССИЙСКОЙ ФЕДЕРАЦИИ

Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Сибирский государственный университет телекоммуникаций и
информатики»

Кафедра телекоммуникационных систем и вычислительных средств
(ТС и ВС)

Отчет по лабораторной работе
по курсу "Системы искусственного интеллекта"

по теме:
ПЕРВИЧНЫЙ АНАЛИЗ ДАННЫХ

Студент:
Группа ИА-331

Гмыря Я.А

Преподаватели:
Преподаватель

Брагин К.И

Новосибирск 2026 г.

СОДЕРЖАНИЕ

ВВЕДЕНИЕ

1.1 Цель

Изучение программных средств для организации рабочего места специалиста по анализу данных и машинному обучению.

1.2 Задачи

1. Получение программного доступа к данным, содержащимся в источниках различного типа;
2. Выполнение предварительного анализа данных и получение обобщенных характеристик наборов данных;
3. Исследование простых методов визуализации данных;
4. Изучение основных библиотек Python для работы с данными.

ТЕОРИЯ

2.1 Используемые инструменты

В ходе работы использовались такие библиотеки как NumPy, Pandas, matplotlib.

2.1.1 NumPy

NumPy (Numerical Python) — библиотека для быстрых вычислений с массивами чисел. Её ключевой объект — `ndarray` (n-мерный массив). Главная фишка: операции выполняются над массивами целиком, без Python-циклов. Это очень ускоряет код. Помимо этого в библиотеке есть много математических функций.

2.1.2 Pandas

Pandas — библиотека для работы с табличными и временными данными. Основные типы данных: `series` — столбец данных, `DataFrame` — таблица. Позволяет удобно считывать `.csv` файлы и анализировать их (подсчет статистических метрик, группировка записей по признаку и т.д.).

2.1.3 matplotlib

Matplotlib - библиотека для построения графиков разной сложности (2D и 3D). Построение графиков происходит через `pyplot` — быстрый и простой интерфейс.

ПРАКТИКА

3.1 Выбор данных для анализа

Для анализа я выбрал небольшую базу данных с описанием флагов разных стран.

3.2 Описание набора данных

Набор данных содержит N строк, в каждой из которых записаны следующие данные:

1. name: Name of the country concerned
2. landmass: 1=N.America, 2=S.America, 3=Europe, 4=Africa, 4=Asia, 6=Oceania
3. zone: Geographic quadrant, based on Greenwich and the Equator; 1=NE, 2=SE, 3=SW, 4=NW area: in thousands of square km
4. population: in round millions
5. language: 1=English, 2=Spanish, 3=French, 4=German, 5=Slavic, 6=Other Indo-European, 7=Chinese, 8=Arabic, 9=Japanese/Turkish/Finnish/Magyar, 10=Others
6. religion: 0=Catholic, 1=Other Christian, 2=Muslim, 3=Buddhist, 4=Hindu, 5=Ethnic, 6=Marxist, 7=Others
7. bars: Number of vertical bars in the flag
8. stripes: Number of horizontal stripes in the flag
9. colours: Number of different colours in the flag
10. red: 0 if red absent, 1 if red present in the flag
11. green: same for green
12. blue: same for blue
13. gold: same for gold (also yellow)
14. white: same for white
15. black: same for black
16. orange: same for orange (also brown)

17. mainhue: predominant colour in the flag (tie-breaks decided by taking the topmost hue, if that fails then the most central hue, and if that fails the leftmost hue)
18. circles: Number of circles in the flag
19. crosses: Number of (upright) crosses
20. saltires: Number of diagonal crosses
21. quarters: Number of quartered sections
22. sunstars: Number of sun or star symbols
23. crescent: 1 if a crescent moon symbol present, else 0
24. triangle: 1 if any triangles present, 0 otherwise
25. icon: 1 if an inanimate image present (e.g., a boat), otherwise 0
26. animate: 1 if an animate image (e.g., an eagle, a tree, a human hand) present, 0 otherwise
27. text: 1 if any letters or writing on the flag (e.g., a motto or slogan), 0 otherwise
28. topleft: colour in the top-left corner (moving right to decide tie-breaks)
29. botright: Colour in the bottom-left corner (moving left to decide tie-breaks)

Пример:

```
Afghanistan ,5 ,1 ,648 ,16 ,10 ,2 ,0 ,3 ,5 ,
1 ,1 ,0 ,1 ,1 ,1 ,0 ,green ,0 ,0 ,0 ,0 ,1 ,0 ,0 ,1 ,0 ,0 ,black ,green
```

3.3 Анализ данных

3.3.1 Считывание данных

С помощью библиотеки pandas считаем данные из файла:

```
data = pd.read_csv(data_file , sep=" , ")
```

3.3.2 Подсчет статистических метрик

Библиотека pandas предоставляет удобный способ группировки данных и подсчета статистических метрик. Сгруппируем страны по регионам и для каждого региона составим статистику о внешнем виде флагов (цвета, фигуры, изображения и т.д.)

```

info = data.groupby([ "landmass" ]).agg(
    #colors
    green=( "green" , "sum" ) ,
    red=( "red" , "sum" ) ,
    gold=( "gold" , "sum" ) ,
    blue=( "blue" , "sum" ) ,
    white=( "white" , "sum" ) ,
    black=( "black" , "sum" ) ,
    orange=( "orange" , "sum" ) ,

    #figure
    circles=( "circles" , "sum" ) ,
    sunstars=( "sunstars" , "sum" ) ,
    quarters=( "quarters" , "sum" ) ,
    crosses=( "crosses" , "sum" ) ,
    saltires=( "saltires" , "sum" ) ,
    animate=( "animate" , "sum" ) ,
    icon=( "icon" , "sum" ) ,

    #text
    text=( "text" , "sum" ) ,

    #count
    count=( "country" , "count" ) ,

)

```

Переменная info будет принадлежать типу данных DataFrame, который представляет из себя таблицу. Можно вывести переменную info с помощью print(), а лучше записать в файл. Получим вот такую таблицу:

landmass	green	red	gold	blue	white	black	orange	circles	sunstars	quarters	crosses	saltires	animate	icon	text	count
N. America	13	21	16	24	26	11	6	6	87	6	7	6	13	9	5	31
S. America	7	13	11	12	14	4	1	3	36	7	1	1	3	3	3	17
Europe	7	29	15	18	27	6	2	1	5	1	10	1	4	9	1	35
Africa	43	42	27	16	28	17	7	6	30	3	2	3	7	9	2	52
Asia	17	32	10	13	32	11	7	14	45	4	1	1	6	13	4	39
Oceania	4	16	12	16	19	3	3	3	66	8	8	6	6	6	1	20

Рисунок 1 — Таблица со статистикой

3.4 Построение графиков

Анализировать такие большие таблицы неудобно, поэтому с помощью библиотеки `matplotlib` построим диаграммы.

Отообразим распределение государств по регионам:




Рисунок 2 — Диаграмма распределения стран по регионам

Можно увидеть, что в Европе, Азии и Африки сконцентрированно наибольшее кол-во стран.

Для каждого региона построим по 2 диаграммы, которые будут показывать соотношение цветов флагов в регионе и соотношение фигур на флаге (крестки, кружки, звезды и т.д.):




Рисунок 3 — Диаграммы соотношения цветов и фигур в регионах

ВЫВОД

В ходе проделанной работы я познакомился с библиотеками языка Python, предназначенных для анализа и визуализации данных, и применил полученные знания на практике: проанализировал с помощью библиотек небольшой dataset.

4.1 Контрольные вопросы

1. Какие инструментальные средства используются для организации рабочего места специалиста Data Science?
2. Какие библиотеки Python используются для работы в области машинного обучения? Дайте краткую характеристику каждой библиотеке.
3. Почему при реализации систем машинного обучения широкое распространение получили библиотеки Python?

Ответы:

1. Для организации рабочего места специалиста Data Science используется: язык программирования, IDE, библиотеки и фреймворки, базы данных.
2. В области машинного обучения для Python используются библиотеки numpy, pandas, matplotlib (для первичного анализа данных).
3. Python популярен в машинном обучении за счет своего удобства, читаемости кода, большого кол-ва библиотек и фреймворков, кроссплатформенности. Многие модули Python на самом деле написаны на C/C++, что делает код очень быстрым.