

МИНИСТЕРСТВО ЦИФРОВОГО РАЗВИТИЯ, СВЯЗИ И МАССОВЫХ
КОММУНИКАЦИЙ
РОССИЙСКОЙ ФЕДЕРАЦИИ

Федеральное государственное бюджетное образовательное учреждение
высшего образования
”<Сибирский государственный университет телекоммуникаций и
информатики”>

Кафедра телекоммуникационных систем и вычислительных средств
(ТС и ВС)

Отчет по лабораторной работе №6
по курсу ”Системы искусственного интеллекта”

по теме:
ПОСТРОЕНИЕ ПАЙПЛАЙНА ОДНОМЕРНОЙ РЕГРЕССИИ

Студент:
Группа ИА-331

Гмыря Я.А

Предподаватели:
Преподаватель

Брагин К.И

Новосибирск 2026 г.

СОДЕРЖАНИЕ

1	ВВЕДЕНИЕ	3
1.1	Цель	3
1.2	Задачи	3
2	ТЕОРИЯ	4
2.1	Линейная регрессия	4
2.2	Метод наименьших квадратов и функция потерь	5
2.3	Датасет	6
3	ПРАКТИКА	7
3.1	Матрица корреляции	7
3.2	Сравнение реальных значений и предсказанных	8
3.3	Распределение ошибки	9
4	ВЫВОД	10

1 ВВЕДЕНИЕ

1.1 Цель

Разработка единого пайплайна для решения задачи регрессии

1.2 Задачи

1. реализовать конвейер для выполнения всех стадий обработки данных при решении задачи одномерной регрессии;
2. получение теоретических представлений о задаче регрессии;
3. получение навыков использования пайплайна при решении задачи машинного обучения;
4. получение навыков рефакторинга кода в задачах машинного обучения.

2 ТЕОРИЯ

2.1 Линейная регрессия

Линейная регрессия (Linear regression) — один из простейших алгоритмов машинного обучения, описывающий зависимость целевой переменной от признака в виде линейной функции:

$$y = kx + b.$$

В данном случае была представлена простая (или парная) линейная регрессия, а уравнение вида

$$f_{w,b}(x) = w_0x_0 + w_1x_1 + \dots + w_nx_n + b = \mathbf{w} \cdot \mathbf{x} + b$$

называется множественной линейной регрессией, где b — смещение модели, $\mathbf{w}$ — вектор её весов, а $\mathbf{x}$ — вектор признаков одного обучающего образца.

К другим условиям определения линейной регрессии относятся гомоскедастичность (дисперсия остатков постоянна и конечна), а также отсутствие мультиколлинеарности (линейной зависимости между признаками).




Рисунок 1 — Интуиция линейной регрессии

2.2 Метод наименьших квадратов и функция потерь

Выбор регрессионной линии (плоскости), описывающей взаимосвязь данных наилучшим образом, заключается в минимизации функции потерь J , представленной в виде среднеквадратичной ошибки. Проще говоря, линия должна проходить через данные таким образом, чтобы в среднем разница квадратов ожидаемых и реальных значений была минимальна. Данный метод называется методом наименьших квадратов.

При наличии же большого количества выбросов в данных, более эффективным может оказаться метод наименьших модулей, однако у него есть один серьёзный недостаток: функция модуля не является дифференцируемой в точке $x=0$, что в ряде случаев может затруднить минимизацию ошибки модели. Следовательно, исходя из теоремы Гаусса-Маркова, метод наименьших квад-

ратов является наиболее оптимальной оценкой параметров модели среди всех линейных и несмещённых оценок за счёт меньшей дисперсии.

2.3 Датасет

Variable Name	Role	Type	Description	Units
VendorName	Feature	Categorical	(adviser, amdahl, apollo, basf, bti, burroughs, c.r.d, cambex, cdc, dec, dg, formation, four-phase, gould, honeywell, hp, ibm, ipl, magnuson, microdata, nas, ncr, nixdorf, perkin-elmer, prime, siemens, sperry, stratus, wang)	
ModelName	Feature	Categorical	many unique symbols	
MYCT	Feature	Integer	machine cycle time	nanoseconds
MMIN	Feature	Integer	minimum main memory	kilobytes
MMAX	Feature	Integer	maximum main memory	kilobytes
CACH	Feature	Integer	cache memory	kilobytes
CHMIN	Feature	Integer	minimum channels	units
CHMAX	Feature	Integer	maximum channels	units
PRP	Feature	Integer	published relative performance	
ERP	Feature	Integer	estimated relative performance from the original article	

3 ПРАКТИКА

Построим модель линейной регрессии. За целевую переменную возьмем параметр PRP.

3.1 Матрица корреляции




Рисунок 2 — Матрица корреляции

Матрица корреляции показывает зависимости между признаками. По матрице выше можно сказать, что почти все признаки неплохо коррелируют друг с другом.

3.2 Сравнение реальных значений и предсказанных




Рисунок 3 — Сравнение реальных значений и предсказанных

Красной линией показано идеальное расположение ответов модели, когда предсказанное значение точно совпадает с реальными.

Здесь есть небольшие расхождения ответов с реальными данными. В начале расхождения меньше, чем в конце. Скорее всего это связано с выбросами




Рисунок 4 — Ошибка

Ошибку лучше видно на графике выше. В начале ошибка намного меньше.

3.3 Распределение ошибки




Рисунок 5 — Распределение ошибки

Ошибка имеет около-нормальное распределение.

4 ВЫВОД

В ходе проделанной работы я познакомился с линейной одномерной регрессией и построил простую модель и проанализировал результат