

МИНИСТЕРСТВО ЦИФРОВОГО РАЗВИТИЯ, СВЯЗИ И МАССОВЫХ
КОММУНИКАЦИЙ
РОССИЙСКОЙ ФЕДЕРАЦИИ

Федеральное государственное бюджетное образовательное учреждение
высшего образования
”<Сибирский государственный университет телекоммуникаций и
информатики”>

Кафедра телекоммуникационных систем и вычислительных средств
(ТС и ВС)

Отчет по лабораторной работе №7
по курсу ”Системы искусственного интеллекта”

по теме:
ИСПОЛЬЗОВАНИЕ РАЗРАБОТАННОГО ПАЙПЛАЙНА ДЛЯ
МНОГОМЕРНОЙ РЕГРЕССИИ

Студент:
Группа ИА-331

Гмыря Я.А

Предподаватели:
Преподаватель

Брагин К.И

Новосибирск 2026 г.

СОДЕРЖАНИЕ

1	ВВЕДЕНИЕ	3
1.1	Цель	3
1.2	Задачи	3
2	ТЕОРИЯ	4
2.1	Линейная регрессия	4
2.2	Метод наименьших квадратов и функция потерь	5
2.3	Датасет	6
2.4	Значимые переменные	6
3	ПРАКТИКА	8
3.1	Backward Elimination	8
3.2	Анализ результатов итоговой модели	9
4	ВЫВОД	12

1 ВВЕДЕНИЕ

1.1 Цель

Научиться применять разработанный пайплайн для тиражирования кода с целью решения широкого круга задач машинного обучения

1.2 Задачи

1. получение навыков рефакторинга кода в проектах машинного обучения;
2. получение навыков определения ключевых признаков в задачах машинного обучения;
3. получение навыков реализации ключевых стратегий оптимизации моделей регрессии.

2 ТЕОРИЯ

2.1 Линейная регрессия

Линейная регрессия (Linear regression) — один из простейших алгоритмов машинного обучения, описывающий зависимость целевой переменной от признака в виде линейной функции:

$$y = kx + b.$$

В данном случае была представлена простая (или парная) линейная регрессия, а уравнение вида

$$f_{w,b}(x) = w_0x_0 + w_1x_1 + \dots + w_nx_n + b = \mathbf{w} \cdot \mathbf{x} + b$$

называется множественной линейной регрессией, где b — смещение модели, $\mathbf{w}$ — вектор её весов, а $\mathbf{x}$ — вектор признаков одного обучающего образца.

К другим условиям определения линейной регрессии относятся гомоскедастичность (дисперсия остатков постоянна и конечна), а также отсутствие мультиколлинеарности (линейной зависимости между признаками).




Рисунок 1 — Интуиция линейной регрессии

2.2 Метод наименьших квадратов и функция потерь

Выбор регрессионной линии (плоскости), описывающей взаимосвязь данных наилучшим образом, заключается в минимизации функции потерь J , представленной в виде среднеквадратичной ошибки. Проще говоря, линия должна проходить через данные таким образом, чтобы в среднем разница квадратов ожидаемых и реальных значений была минимальна. Данный метод называется методом наименьших квадратов.

При наличии же большого количества выбросов в данных, более эффективным может оказаться метод наименьших модулей, однако у него есть один серьёзный недостаток: функция модуля не является дифференцируемой в точке $x=0$, что в ряде случаев может затруднить минимизацию ошибки модели. Следовательно, исходя из теоремы Гаусса-Маркова, метод наименьших квад-

ратов является наиболее оптимальной оценкой параметров модели среди всех линейных и несмещённых оценок за счёт меньшей дисперсии.

2.3 Датасет

Variable Name	Role	Type	Description	Units
VendorName	Feature	Categorical	(adviser, amdahl, apollo, basf, bti, burroughs, c.r.d, cambex, cdc, dec, dg, formation, four-phase, gould, honeywell, hp, ibm, ipl, magnuson, microdata, nas, ncr, nixdorf, perkin-elmer, prime, siemens, sperry, stratus, wang)	
ModelName	Feature	Categorical	many unique symbols	
MYCT	Feature	Integer	machine cycle time	nanoseconds
MMIN	Feature	Integer	minimum main memory	kilobytes
MMAX	Feature	Integer	maximum main memory	kilobytes
CACH	Feature	Integer	cache memory	kilobytes
CHMIN	Feature	Integer	minimum channels	units
CHMAX	Feature	Integer	maximum channels	units
PRP	Feature	Integer	published relative performance	
ERP	Feature	Integer	estimated relative performance from the original article	

2.4 Значимые переменные

Значимые переменные - признаки, которые реально влияют на целевую переменную, т.е влияют на предсказания модели.


1. All-in. В данном подходе производится включение всех признаков в модель.

2. Backward Elimination. В подходе предполагается обучение модели с учетом всех признаков и удаление признаков по одному на основе их значимости до достижения ситуации, когда останутся только значимые признаки.
3. Forward Selection. Подход предполагает начальное тестирование модели с одним признаком (тестируется каждый признак). Затем добавляются по одному наиболее значимые признаки.
4. Bidirectional Elimination. Подход совмещает стратегии 2 и 3.
5. Score Comparison.

3 ПРАКТИКА

3.1 Backward Elimination

После считывания данных из датасета приступим к процедуре **Backward Elimination** - построим линейную регрессию на всех признаках, а потом будем выкидывать на каждой итерации по одному признаку, который влияет меньше всего. Порог выбора равен 0.05, т.е если метрика $pvalue > 0.05$, то такой признак отбрасывается. $pvalue$ показывает, насколько признак НЕ влияет на предсказания модели.



```
Удаляем: CASH (p-value=0.7360894812385995)
Удаляем: CHMIN (p-value=0.5886731730390253)
Удаляем: const (p-value=0.32602615364635423)
Удаляем: MYCT (p-value=0.6718938883832951)
Удаляем: MMIN (p-value=0.12231841604219107)
Удаляем: MMAX (p-value=0.16886324797123034)
```

Рисунок 2 — Логи работы метода BE

Модель посчитала, что значимыми признаками являются только CHMAX и ERP.


3.2 Анализ результатов итоговой модели

OLS Regression Results					
Dep. Variable:	PRP	R-squared (uncentered):	0.946		
Model:	OLS	Adj. R-squared (uncentered):	0.945		
Method:	Least Squares	F-statistic:	1433.		
Date:	Tue, 28 Apr 2026	Prob (F-statistic):	5.16e-105		
Time:	10:01:59	Log-Likelihood:	-852.22		
No. Observations:	167	AIC:	1708.		
Df Residuals:	165	BIC:	1715.		
Df Model:	2				
Covariance Type:	nonrobust				
	coef	std err	t	P> t	[0.025 0.975]
CHMAX	0.4627	0.150	3.075	0.002	0.166 0.760
ERP	0.9961	0.028	35.631	0.000	0.941 1.051
Omnibus:	80.231	Durbin-Watson:		1.780	
Prob(Omnibus):	0.000	Jarque-Bera (JB):		881.151	
Skew:	1.418	Prob(JB):		4.58e-192	
Kurtosis:	13.890	Cond. No.		7.74	

Рисунок 3 — Результаты итоговой модели

1. **Dep. Variable** — целевая переменная, которую предсказывает модель (PRP).
2. **Model (OLS)** — используется линейная регрессия (метод наименьших квадратов).
3. **Method (Least Squares)** — способ оценки коэффициентов: минимизация суммы квадратов ошибок.
4. **No. Observations** — количество наблюдений (объектов в данных).
5. **Df Model** — число признаков в модели.
6. **Df Residuals** — степени свободы остатков (количество наблюдений минус число параметров).
7. **R-squared (uncentered)** — доля объяснённой дисперсии (качество модели), без учёта константы.
8. **Adj. R-squared** — скорректированный R^2 с учётом числа признаков.
9. **F-statistic** — проверяет значимость модели в целом.
10. **Prob (F-statistic)** — p-value для всей модели (если близко к 0 — модель значима).
11. **Log-Likelihood** — мера качества модели (чем больше, тем лучше).
12. **AIC** — критерий качества с учётом сложности (меньше — лучше).
13. **BIC** — аналог AIC, сильнее штрафует сложные модели.

14. **coef** — коэффициенты регрессии (влияние признака на целевую переменную).
15. **std err** — стандартная ошибка коэффициента (точность оценки).
16. **t** — t-статистика (насколько значим коэффициент).
17. **P>|t|** — p-value признака (если < 0.05 , признак значим).
18. **[0.025, 0.975]** — 95% доверительный интервал для коэффициента.
19. **Omnibus** — тест на нормальность распределения остатков.
20. **Prob(Omnibus)** — p-value теста Omnibus.
21. **Jarque-Bera (JB)** — ещё один тест нормальности остатков.
22. **Prob(JB)** — p-value теста Jarque-Bera.
23. **Skew** — асимметрия распределения остатков.
24. **Kurtosis** — “тяжесть хвостов” распределения (наличие выбросов).
25. **Durbin-Watson** — проверка автокорреляции ошибок (≈ 2 — норма).
26. **Cond. No** — показатель мультиколлинеарности (большое значение — проблема).



```
MAE: 30.87676647455457
RMSE: 46.75923674610923
R2: 0.9570504542172433
```

Рисунок 4 — Оценка модели




Рисунок 5 — Регрессионная плоскость

Поскольку модель выбрала всего 2 признака, то можно изобразить регрессионную плоскость в 3D пространстве.

4 ВЫВОД

В ходе проделанной работы я познакомился с линейной одномерной регрессией и построил простую модель и проанализировал результат