

МИНИСТЕРСТВО ЦИФРОВОГО РАЗВИТИЯ, СВЯЗИ И МАССОВЫХ
КОММУНИКАЦИЙ
РОССИЙСКОЙ ФЕДЕРАЦИИ

Федеральное государственное бюджетное образовательное учреждение
высшего образования
”<Сибирский государственный университет телекоммуникаций и
информатики”>

Кафедра телекоммуникационных систем и вычислительных средств
(ТС и ВС)

Отчет по лабораторной работе №9
по курсу ”Системы искусственного интеллекта”

по теме:
КЛАСТЕРИЗАЦИЯ

Студент:
Группа ИА-331

Гмыря Я.А

Предподаватели:
Преподаватель

Брагин К.И

Новосибирск 2026 г.

СОДЕРЖАНИЕ

1	ВВЕДЕНИЕ	3
1.1	Цель	3
1.2	Задачи	3
2	ТЕОРИЯ	4
3	ПРАКТИКА	7
3.1	Построение кластеризации	7
4	ВЫВОД	10

1 ВВЕДЕНИЕ

1.1 Цель

Научится производить кластерный анализ данных на основе метода К-средних.

1.2 Задачи

1. Получение навыков рефакторинга кода в проектах машинного обучения;
2. Изучение принципов определения оптимального количества кластеров в методах кластерного анализа;
3. Изучение возможностей языка Python для реализации кластерного анализа.

2 ТЕОРИЯ

Кластеризация — это набор методов обучения без учителя для группировки данных по определённым критериям в так называемые кластеры, что позволяет выявлять сходства и различия между объектами, а также упрощать их анализ и визуализацию. Из-за частичного сходства в постановке задач с классификацией кластеризацию также называют *unsupervised classification*.

Классификация методов кластеризации

По способу формирования кластеров выделяют следующие группы методов:

- **Разделительные (partitioning)** — разбивают данные на заданное число кластеров, минимизируя расстояние внутри кластера и максимизируя расстояние между кластерами (например, K-means).
- **Основанные на плотности (density-based)** — группируют точки, находящиеся в областях с высокой плотностью, и отделяют их от областей с низкой плотностью (например, DBSCAN).
- **Основанные на сетке (grid-based)** — разбивают пространство на ячейки сетки и анализируют плотность данных в каждой ячейке (например, STING).
- **Основанные на модели (model-based)** — предполагают, что данные порождены некоторой статистической моделью и подбирают параметры этой модели (например, смеси Гауссианов).
- **Основанные на графах (graph-based)** — используют графовое представление данных и разбивают его на подграфы, соответствующие кластерам (например, спектральная кластеризация).
- **Основанные на подпространствах (subspace-based)** — ищут кластеры в подпространствах признаков, а не во всём пространстве (например, CLIQUE).
- **Основанные на ансамбле (ensemble-based)** — комбинируют результаты различных алгоритмов кластеризации для получения более стабильного и надёжного разбиения (например, CSPA).

Метод К-средних

Кластеризация К-средних (*K-means*) представляет собой одну из самых простых и популярных реализаций. Суть метода заключается в итеративной процедуре:

1. Инициализация центроидов кластеров.
2. Назначение каждой точки ближайшему центроиду.
3. Пересчёт центроидов как среднего арифметического точек, принадлежащих кластеру.
4. Повторение шагов 2–3 до сходимости.

Оптимизация выполняется за счёт минимизации функции суммарного квадратичного отклонения точек от центроидов:

$$J = \sum_{k=1}^K \sum_{x_i \in C_k} \|x_i - \mu_k\|^2$$

где:

- K — число кластеров,
- C_k — множество точек кластера k ,
- μ_k — центр (центроид) кластера k .




Рисунок 1 — K-means

Описание датасета *Seeds*

В работе используется датасет *Seeds*, содержащий геометрические характеристики зёрен пшеницы. Каждый объект представляет собой отдельное зерно, описанное набором числовых признаков.

Датасет включает следующие признаки:

- **area** — площадь зерна;
- **perimeter** — периметр зерна;
- **compactness** — компактность, рассчитываемая как отношение площади к квадрату периметра;
- **length_kernel** — длина ядра зерна;
- **width_kernel** — ширина ядра зерна;
- **asymmetry** — коэффициент асимметрии зерна;
- **groove_length** — длина бороздки зерна;
- **class** — класс зерна (тип пшеницы).

Все признаки, кроме **class**, являются вещественными числовыми величинами и используются для кластеризации. Признак **class** представляет собой категориальную переменную, принимающую значения 1, 2 или 3, и может использоваться для оценки качества кластеризации.

3 ПРАКТИКА

3.1 Построение кластеризации

Построим модель кластеризации и визуализируем результат




Рисунок 2 — Визуализации кластеризации

Можем увидеть, что модель разбила семена на 3 группы (кластера).

Интерпретация silhouette plot

Также для анализа качества кластеризации используется **silhouette plot**.




Рисунок 3 — Качество кластеризации

Данный график представляет собой **silhouette plot**, используемый для оценки качества кластеризации.

1. **Ось x** — значение silhouette coefficient для каждого объекта:
 - $s \approx 1$ — объект хорошо принадлежит своему кластеру;
 - $s \approx 0$ — объект находится на границе между кластерами;
 - $s < 0$ — возможная неправильная кластеризация.
2. **Ось y** — номера кластеров. Каждый цветной блок соответствует отдельному кластеру.
3. **Синяя вертикальная линия** — среднее значение silhouette coefficient по всей выборке.
4. **Интерпретация результата:**
 - среднее значение около 0.4 указывает на *умеренно хорошее* качество кластеризации;
 - большинство значений положительные, что говорит о корректном разделении кластеров;
 - наличие значений ближе к 0 указывает на пересечение границ кластеров.

Метод «локтя» (Elbow Method)

Метод «локтя» используется для выбора оптимального числа кластеров k в алгоритмах кластеризации, таких как K -means.




Рисунок 4 — Метод локтя

На графике по оси x отложено число кластеров k , а по оси y — значение инерции, которое определяется как сумма квадратов расстояний между объектами и центрами их кластеров:

$$J(k) = \sum_{i=1}^k \sum_{x \in C_i} \|x - \mu_i\|^2$$

где C_i — множество объектов в i -м кластере, а μ_i — центр соответствующего кластера.

С увеличением числа кластеров значение инерции монотонно уменьшается, однако после некоторого значения k улучшение качества разбиения становится незначительным. Эта точка называется «локтем».

По представленному графику видно, что резкое снижение инерции происходит при $k = 1$ до $k = 3$, после чего уменьшение становится более плавным. Следовательно, оптимальное число кластеров находится в области $k \approx 3$ (возможно $k = 4$).

4 ВЫВОД

В ходе проделанной работы я познакомился с идеей кластеризации и построил модель на основе метода k-means и проверил ее эффективность.